



LISTA DE EXERCÍCIOS

DISCIPLINA: Introdução ao Machine Learning

CURSO: Mestrado em Administração Pública

ÁREA DE CONCENTRAÇÃO: Ciência de Dados e Inteligência Artificial

DOCENTE RESPONSÁVEL: Roberta Moreira Wichmann

E-MAIL: roberta.wichmann@idp.edu.br

ANO E BIMESTRE DE REFERÊNCIA: 2025/2

DATA DA MONITORIA: 02/10/2025 **LOCAL:** ON LINE **HORÁRIO:** 19:30h às 20:30h

MONITOR: Mateus Rocha (mattrocha57@gmail.com)

DISCENTE: Igo Costa

ENTREGA DA LISTA RESOLVIDA PARA A PROFESSORA: dia 25/10/2025

Conforme plano de ensino da disciplina, o discente poderá realizar essa atividade complementar, de caráter optativo, que acrescentará até 1 (um) ponto à nota da segunda atividade avaliativa, a qual corresponde a 60% da nota final da disciplina.

Questão 1) Com relação a diferença entre aprendizado supervisionado e aprendizado não supervisionado, assinale se as afirmações são **verdadeiras (V) ou falsas (F)**: (0,10 ponto)

- i. (F) Aprendizado supervisionado sempre utiliza algoritmos mais complexos, enquanto aprendizado não supervisionado sempre utiliza algoritmos mais simples;
- ii. (V) Aprendizado supervisionado requer dados rotulados (com a resposta desejada), enquanto aprendizado não supervisionado não requer rotulagem, buscando encontrar padrões nos dados brutos;
- iii. (F) Aprendizado supervisionado não é utilizado para problemas de classificação, enquanto aprendizado não supervisionado é sempre utilizado para problemas de regressão;
- iv. (F) Aprendizado supervisionado é mais adequado para análise exploratória de dados, enquanto aprendizado não supervisionado é mais adequado para previsão.

**Questão 2) (0,20 ponto)**

(i) Descreva qual a fórmula para o Erro Quadrático Médio (MSE) e para a Raiz do Erro Quadrático Médio (RMSE) e,

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Onde:

- n é o número total de observações na amostra.
- y_i é o valor real da i -ésima observação.
- $\hat{y}_i$ é o valor previsto pelo modelo para a i -ésima observação.

O cálculo consiste em:

1. Subtrair o valor previsto do valor real para cada observação ($y_i - \hat{y}_i$).
2. Elevar o resultado de cada subtração ao quadrado.
3. Somar todos os resultados e dividir pelo número total de observações (n).

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

A Raiz do Erro Quadrático Médio (RMSE) é a métrica obtida ao se extrair a raiz quadrada do Erro Quadrático Médio (MSE). A principal característica deste cálculo está na etapa de elevar os erros individuais ao quadrado $(y_i - \hat{y}_i)^2$. Essa operação amplifica o impacto dos erros maiores, atribuindo-lhes um peso desproporcionalmente alto. Consequentemente, o modelo é mais rigorosamente penalizado por previsões muito distantes dos valores reais em comparação com erros pequenos. A etapa final, a extração da raiz quadrada, tem a função de retornar a métrica para a mesma unidade da variável original, facilitando sua interpretação.

(ii) interprete o que os valores dessas métricas indicam sobre a qualidade de um modelo preditivo.

O Erro Quadrático Médio (MSE) e a Raiz do Erro Quadrático Médio (RMSE) são métricas fundamentais para avaliar a qualidade de um modelo preditivo, quantificando a magnitude de seus erros. A regra geral para ambas é que **quanto menor o valor, melhor o desempenho do modelo**.



O RMSE é o mais fácil de entender. Pense nele como uma régua que mede o erro do modelo, e o legal é que a medida está na mesma unidade do que a gente está tentando prever (como Reais, quilos, etc.). Então, se estamos prevendo preços de casas e o RMSE dá R\$ 50.000, quer dizer que, na média, o modelo costuma errar por uns R\$ 50.000 para mais ou para menos. É uma medida direta do tamanho do erro típico.

Já o MSE é mais esquisito. O valor dele é em "unidades ao quadrado" (tipo Reais ao quadrado), o que não faz muito sentido na nossa cabeça. Por isso, a gente não usa muito para interpretar o erro. A principal utilidade dele é para comparar modelos: se o Modelo A tem um MSE menor que o Modelo B, ele é melhor. Além disso, o computador usa o MSE "por baixo dos panos" para aprender, porque essa parte de "elevar ao quadrado" dá uma bronca maior no modelo quando ele comete um erro muito grande.

Resumindo: a gente olha o RMSE pra ter uma ideia clara do tamanho do erro. E a gente usa o MSE pra saber qual modelo é melhor que o outro.

Questão 3) Considere os seguintes resultados de dois modelos preditivos aplicados a um problema de classificação binária, onde o objetivo é classificar se um indivíduo possui ou não COVID (ter a COVID é a classe positiva).

Modelo A: Acurácia = 0.85, Precisão = 0.70, Recall = 0.60, F1-score = 0.65

Modelo B: Acurácia = 0.78, Precisão = 0.80, Recall = 0.50, F1-score = 0.62

Com base nessas métricas, qual modelo você consideraria o melhor? Marque com (X) a sua resposta. Justifique sua resposta, explicando como você interpreta cada métrica e por que escolheu o modelo que você selecionou. Considere também o contexto do problema (quais são as consequências de um falso positivo versus um falso negativo?) **(0,25 ponto)**

Melhor modelo é o modelo A (X)

Melhor modelo é o modelo B ()

A análise parte do entendimento de que o problema é de **aprendizado supervisionado do tipo classificação**, pois o objetivo é prever uma de duas categorias ("Tem COVID" ou "Não Tem COVID"). Para avaliar qual modelo preditivo é o melhor, é fundamental considerar não apenas as métricas, mas principalmente o contexto do problema.

O fator mais crítico aqui é o diagnóstico de uma doença contagiosa. Nesse cenário, um **Falso Negativo** (não diagnosticar uma pessoa doente) é um erro muito mais grave e



perigoso do que um Falso Positivo. Portanto, a prioridade é escolher o modelo que melhor evita os Falsos Negativos.

A métrica que mede diretamente essa capacidade é o **Recall**. Comparando os modelos, o **Modelo A (Recall = 0.60)** é claramente superior ao Modelo B (Recall = 0.50). Isso significa que o Modelo A consegue encontrar 60% de todas as pessoas realmente doentes, sendo mais eficaz na sua missão principal.

Embora o Modelo B seja mais **preciso** (0.80 vs 0.70), o que indica que ele gera menos "alarmes falsos", essa vantagem vem ao custo inaceitável de um baixo Recall. A superioridade do Modelo A é também reforçada por sua **Acurácia** geral mais alta (0.85) e por um **F1-Score** (0.65) maior, que aponta um melhor equilíbrio entre Precisão e Recall. Por esses motivos, o Modelo A é a escolha mais segura e tecnicamente mais adequada para esta aplicação.

Questão 4) Qual das seguintes sequências de etapas **MELHOR** descreve o fluxo de trabalho (*workflow*) típico para a construção de um modelo de Machine Learning supervisionado? Marque com (X) a resposta CORRETA: (0,20 ponto)

- i. (X) Coleta de dados -> Divisão e pré-processamento -> Treinamento e otimização de hiperparâmetros -> Seleção do modelo -> Avaliação do modelo na base de teste -> Implantação;
- ii. () Seleção do modelo -> Coleta de dados -> Treinamento e otimização de hiperparâmetros -> Avaliação do modelo na base de teste -> Divisão e pré-processamento -> Implantação;
- iii. () Coleta de dados -> Seleção do modelo -> Treinamento, otimização de hiperparâmetros -> Divisão e pré-processamento -> Avaliação do modelo na base de teste -> Implantação;
- iv. () Coleta de dados -> Divisão e pré-processamento -> Seleção do modelo -> Treinamento e otimização de hiperparâmetros -> Avaliação do modelo na base de teste -> Implantação.

Questão 5) A base de dados "palmerpenguins" (Disponível clicando [aqui](#)) contém informações sobre pinguins, incluindo as colunas: "species" (espécie), "bill_length_mm" (comprimento do bico), "bill_depth_mm" (profundidade do bico), "flipper_length_mm" (comprimento da nadadeira), "body_mass_g" (massa corporal), "sex" (sexo).

Responda os seguintes itens abaixo, com a linguagem python (.py), e suas principais bibliotecas vistas em sala de aula (pandas, matplotlib, numpy, etc) **deixando apenas o resultado do código que será utilizado em cada questão (0,25 ponto):**

- i. Remova quaisquer linhas que contenham valores ausentes (Mostre a quantidade de linhas antes e depois de remover os valores ausentes);




```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 344 entries, 0 to 343
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   rowid                  344 non-null   int64
1   species                 344 non-null   object
2   island                  344 non-null   object
3   bill_length_mm         342 non-null   float64
4   bill_depth_mm          342 non-null   float64
5   flipper_length_mm      342 non-null   float64
6   body_mass_g            342 non-null   float64
7   sex                    333 non-null   object
8   year                   344 non-null   int64
dtypes: float64(4), int64(2), object(3)
memory usage: 24.3+ KB
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 333 entries, 0 to 343
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   rowid                  333 non-null   int64
1   species                 333 non-null   object
2   island                  333 non-null   object
3   bill_length_mm         333 non-null   float64
4   bill_depth_mm          333 non-null   float64
5   flipper_length_mm      333 non-null   float64
6   body_mass_g            333 non-null   float64
7   sex                    333 non-null   object
8   year                   333 non-null   int64
dtypes: float64(4), int64(2), object(3)
memory usage: 26.0+ KB
```

- ii. Crie um gráfico de dispersão (scatter plot) mostrando a relação entre “bill_length_mm” (eixo x) e “bill_depth_mm” (eixo y), colorido por “species” e configure os rótulos dos eixos e o título do gráfico;


Existe alguma relação entre o quão comprido é o bico de um pinguim e o quão profundo (alto) ele é?





iii. Crie um histograma da variável “body_mass_g”, separado por “sex”;

```
Contagem total de pinguins por sexo:
sex
male      168
female    165
Name: count, dtype: int64
```



- iv. Agrupe os dados por espécie e calcule a média da “body_mass_g” para cada espécie. Imprima os resultados.

```
Espécies de pinguins existentes na base de dados:
['Adelie' 'Gentoo' 'Chinstrap']
```

```
Contagem de pinguins por espécie:
species
Adelie      146
Chinstrap    68
Gentoo     119
dtype: int64
```



```
Soma da massa corporal (em gramas) por espécie:  
species  
Adelie      541100.0  
Chinstrap  253850.0  
Gentoo      606000.0  
Name: body_mass_g, dtype: float64
```

```
Média da massa corporal (em gramas) por espécie:  
species  
Adelie      3706.164384  
Chinstrap   3733.088235  
Gentoo      5092.436975  
Name: body_mass_g, dtype: float64
```